

讲堂 > MySQL实战45讲 > 文章详情

## 05 | 深入浅出索引（下）

2018-11-23 林晓斌



### 05 | 深入浅出索引（下）

朗读人：林晓斌 09'53" | 4.53M


在上一篇文章中，我和你介绍了 InnoDB 索引的数据结构模型，今天我们再继续聊聊跟 MySQL 索引有关的概念。

在开始这篇文章之前，我们先来看一下这个问题：

在下面这个表 T 中，如果我执行 `select * from T where k between 3 and 5`，需要执行几次树的搜索操作，会扫描多少行？

下面是这个表的初始化语句。

```
1 mysql> create table T (  
2   ID int primary key,  
3   k int NOT NULL DEFAULT 0,  
4   s varchar(16) NOT NULL DEFAULT '',  
5   index k(k))  
6 engine=InnoDB;  
7
```

 复制代码

```
8 insert into T values(100,1, 'aa'),(200,2, 'bb'),(300,3, 'cc'),(500,5, 'ee'),(600,6, 'ff'),(700,7, 'gg')
```

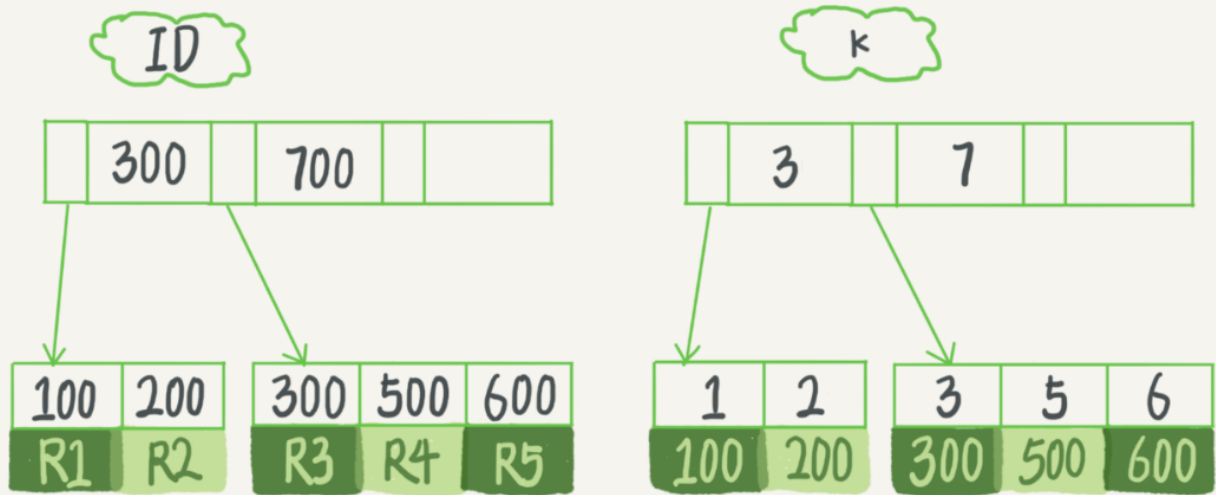


图 1 InnoDB 的索引组织结构

现在，我们一起来看看这条 SQL 查询语句的执行流程：

1. 在 k 索引树上找到 k=3 的记录，取得 ID = 300；
2. 再到 ID 索引树查到 ID=300 对应的 R3；
3. 在 k 索引树取下一个值 k=5，取得 ID=500；
4. 再回到 ID 索引树查到 ID=500 对应的 R4；
5. 在 k 索引树取下一个值 k=6，不满足条件，循环结束。

在这个过程中，**回到主键索引树搜索的过程，我们称为回表**。可以看到，这个查询过程读了 k 索引树的 3 条记录（步骤 1、3 和 5），回表了两次（步骤 2 和 4）。

在这个例子中，由于查询结果所需要的数据只在主键索引上有，所以不得不回表。那么，有没有可能经过索引优化，避免回表过程呢？

## 覆盖索引

如果执行的语句是 `select ID from T where k between 3 and 5`，这时只需要查 ID 的值，而 ID 的值已经在 k 索引树上了，因此可以直接提供查询结果，不需要回表。也就是说，在这个查询里面，索引 k 已经“覆盖了”我们的查询需求，我们称为覆盖索引。

**由于覆盖索引可以减少树的搜索次数，显著提升查询性能，所以使用覆盖索引是一个常用的性能优化手段。**


需要注意的是，在引擎内部使用覆盖索引在索引 k 上其实读了三个记录，R3~R5（对应的索引 k 上的记录项），但是对于 MySQL 的 Server 层来说，它就是找引擎拿到了两条记录，因此 MySQL 认为扫描行数是 2。

备注：关于如何查看扫描行数的问题，我将会在第 16 文章《如何正确地显示随机消息？》中，和你详细讨论。

基于上面覆盖索引的说明，我们来讨论一个问题：**在一个市民信息表上，是否有必要将身份证号和名字建立联合索引？**

假设这个市民表的定义是这样的：

```
1 CREATE TABLE `tuser` (  
2   `id` int(11) NOT NULL,  
3   `id_card` varchar(32) DEFAULT NULL,  
4   `name` varchar(32) DEFAULT NULL,  
5   `age` int(11) DEFAULT NULL,  
6   `ismale` tinyint(1) DEFAULT NULL,  
7   PRIMARY KEY (`id`),  
8   KEY `id_card` (`id_card`),  
9   KEY `name_age` (`name`,`age`)  
10 ) ENGINE=InnoDB
```

 复制代码

我们知道，身份证号是市民的唯一标识。也就是说，如果有根据身份证号查询市民信息的需求，我们只要在身份证号字段上建立索引就够了。而再建立一个（身份证号、姓名）的联合索引，是不是浪费空间？

如果现在有一个高频请求，要根据市民的身份证号查询他的姓名和年龄，这个联合索引就有意义了。它可以在这个高频请求上用到覆盖索引，不再需要回表查整行记录，减少语句的执行时间。

当然，索引字段的维护总是有代价的。因此，在建立冗余索引来支持覆盖索引时就需要权衡考虑了。这正是业务 DBA，或者称为业务数据架构师的工作。

## 最左前缀原则

看到这里你一定有一个疑问，如果为每一种查询都设计一个索引，索引是不是太多了。如果我现在要按照市民的身份证号去查他的家庭地址呢？虽然这个查询需求在业务中出现的概率不高，但总不能让它走全表扫描吧？反过来说，单独为一个不频繁的请求创建一个（身份证号，地址）的索引又感觉有点浪费。应该这么做呢？

这里，我先和你说结论吧。**B+ 树这种索引结构，可以利用索引的“最左前缀”，来定位记录。**

为了直观地说明这个概念，我们用（name，age）这个联合索引来分析。

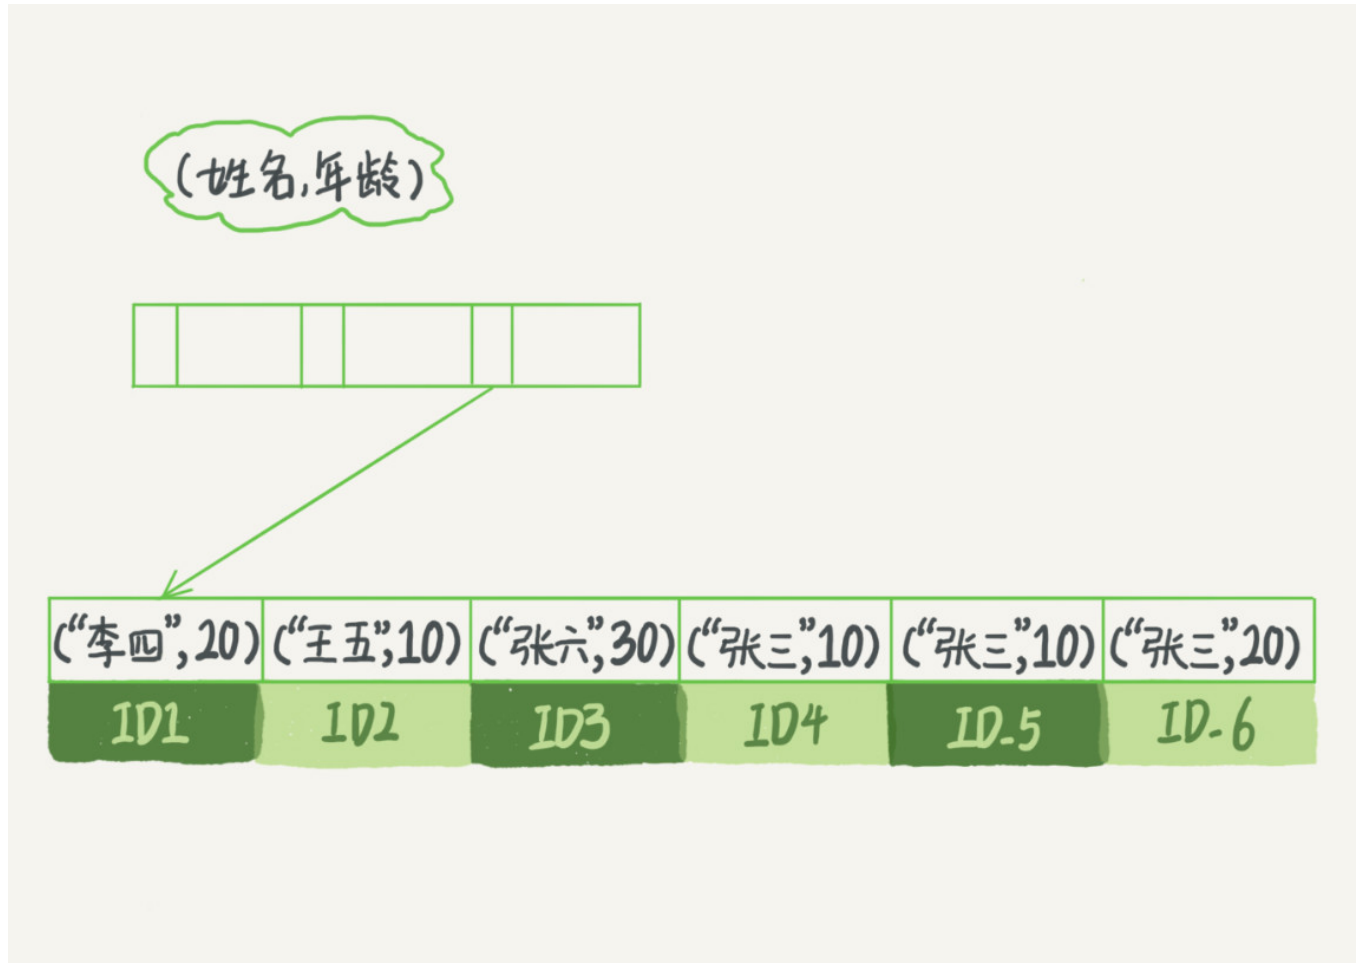


图 2（name，age）索引示意图

可以看到，索引项是按照索引定义里面出现的字段顺序排序的。

当你的逻辑需求是查到所有名字是“张三”的人时，可以快速定位到 ID4，然后向后遍历得到所有需要的结果。

如果你要查的是所有名字第一个字是“张”的人，你的 SQL 语句的条件是 "where name like '张 %' "。这时，你也能够用上这个索引，查找到第一个符合条件的记录是 ID3，然后向后遍历，直到不满足条件为止。

可以看到，不只是索引的全部定义，只要满足最左前缀，就可以利用索引来加速检索。这个最左前缀可以是联合索引的最左 N 个字段，也可以是字符串索引的最左 M 个字符。

基于上面对最左前缀索引的说明，我们来讨论一个问题：**在建立联合索引的时候，如何安排索引内的字段顺序。**

这里我们的评估标准是，索引的复用能力。因为可以支持最左前缀，所以当已经有了 (a,b) 这个联合索引后，一般就不需要单独在 a 上建立索引了。因此，**第一原则是，如果通过调整顺序，可以少维护一个索引，那么这个顺序往往就是需要优先考虑采用的。**

所以现在你知道了，这段开头的问题里，我们要为高频请求创建 (身份证号，姓名) 这个联合索引，并用这个索引支持“根据身份证号查询地址”的需求。

那么，如果既有联合查询，又有基于 a、b 各自的查询呢？查询条件里面只有 b 的语句，是无法使用 (a,b) 这个联合索引的，这时候你不得不维护另外一个索引，也就是说你需要同时维护 (a,b)、(b) 这两个索引。

这时候，我们要**考虑的原则就是空间**了。比如上面这个市民表的情况，name 字段是比 age 字段大的，那我就建议你创建一个 (name,age) 的联合索引和一个 (age) 的单字段索引。

## 索引下推

上一段我们说到满足最左前缀原则的时候，最左前缀可以用于在索引中定位记录。这时，你可能要问，那些不符合最左前缀的部分，会怎么样呢？

我们还是以市民表的联合索引 (name, age) 为例。如果现在有一个需求：检索出表中“名字第一个字是张，而且年龄是 10 岁的所有男孩”。那么，SQL 语句是这么写的：

```
1 mysql> select * from tuser where name like '张 %' and age=10 and ismale=1;
```

[复制代码](#)

你已经知道了前缀索引规则，所以这个语句在搜索索引树的时候，只能用“张”，找到第一个满足条件的记录 ID3。当然，这还不错，总比全表扫描要好。

然后呢？

当然是判断其他条件是否满足。

在 MySQL 5.6 之前，只能从 ID3 开始一个个回表。到主键索引上找出数据行，再对比字段值。

而 MySQL 5.6 引入的索引下推优化 (index condition pushdown)，可以在索引遍历过程中，对索引中包含的字段先做判断，直接过滤掉不满足条件的记录，减少回表次数。

图 3 和图 4，是这两个过程的执行流程图。



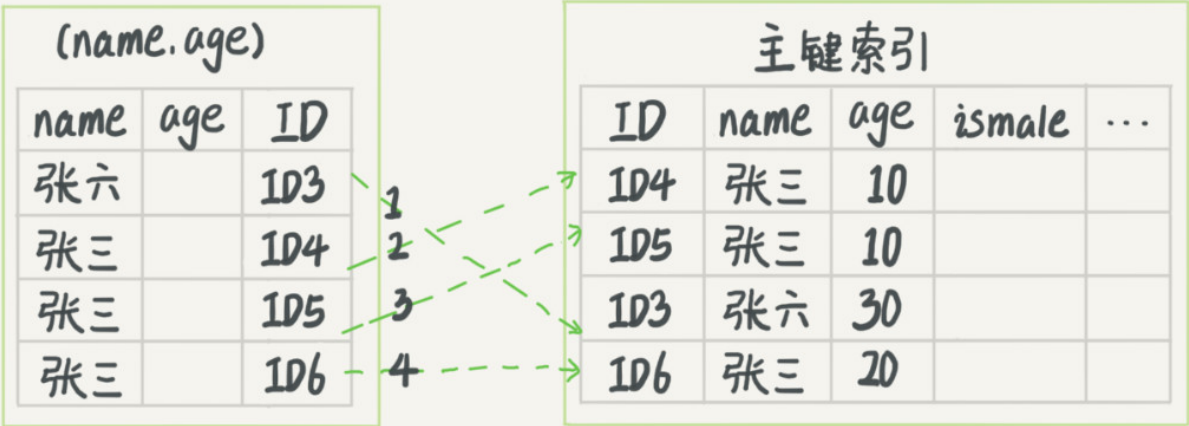


图 3 无索引下推执行流程

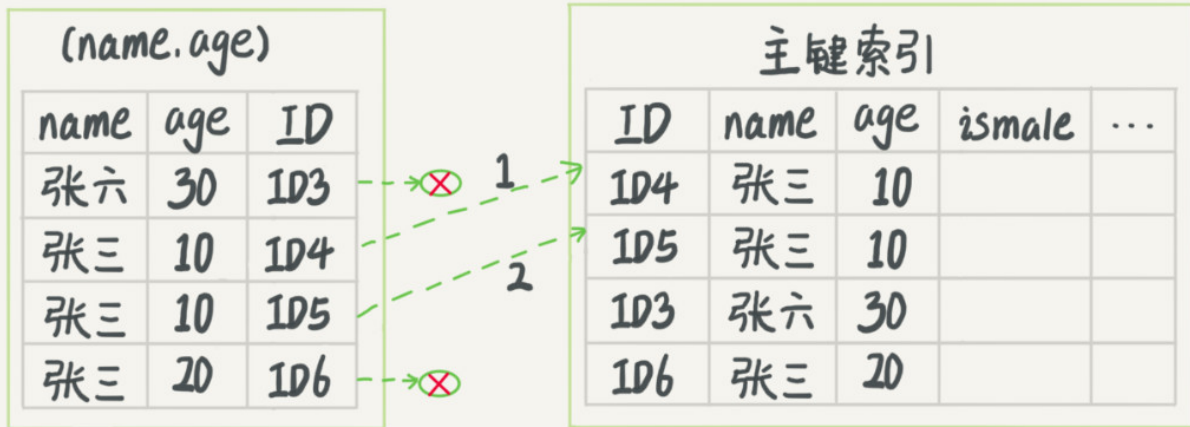


图 4 索引下推执行流程

在图 3 和 4 这两个图里面，每一个虚线箭头表示回表一次。

图 3 中，在 (name,age) 索引里面我特意去掉了 age 的值，这个过程 InnoDB 并不会去看 age 的值，只是按顺序把 “name 第一个字是 ‘张’ ” 的记录一条条取出来回表。因此，需要回表 4 次。

图 4 跟图 3 的区别是，InnoDB 在 (name,age) 索引内部就判断了 age 是否等于 10，对于不等于 10 的记录，直接判断并跳过。在我们的这个例子中，只需要对 ID4、ID5 这两条记录回表取数据判断，就只需要回表 2 次。

## 小结

今天这篇文章，我和你继续讨论了数据库索引的概念，包括了覆盖索引、前缀索引、索引下推。你可以看到，在满足语句需求的情况下，尽量少地访问资源是数据库设计的重要原则之一。我们在使用数据库的时候，尤其是在设计表结构时，也要以减少资源消耗作为目标。

接下来我给你留下一个问题吧。

实际上主键索引也是可以使用多个字段的。DBA 小吕在入职新公司的时候，就发现自己接手维护的库里面，有这么一个表，表结构定义类似这样的：

```
1 CREATE TABLE `geek` (  
2   `a` int(11) NOT NULL,  
3   `b` int(11) NOT NULL,  
4   `c` int(11) NOT NULL,  
5   `d` int(11) NOT NULL,  
6   PRIMARY KEY (`a`,`b`),  
7   KEY `ca` (`c`,`a`),  
8   KEY `cb` (`c`,`b`)  
9 ) ENGINE=InnoDB;
```

[复制代码](#)

公司的同事告诉他说，由于历史原因，这个表需要 a、b 做联合主键，这个小吕理解了。

但是，学过本章内容的小吕又纳闷了，既然主键包含了 a、b 这两个字段，那意味着单独在字段 c 上创建一个索引，就已经包含了三个字段了呀，为什么要创建 “ca” “cb” 这两个索引？

同事告诉他，是因为他们的业务里面有这样的两种语句：

```
1 select ... from geek where c=N order by a;  
2 select ... from geek where c=N order by b;
```

[复制代码](#)

我给你的问题是，这位同事的解释对吗，为了这两个查询模式，这两个索引是否都是必须的？为什么呢？

你可以把你的思考 and 观点写在留言区里，我会在下一篇文章的末尾和你讨论这个问题。感谢你的收听，也欢迎你把这篇文章分享给更多的朋友一起阅读。

## 上期问题时间

上期的问题是，通过两个 alter 语句重建索引 k，以及通过两个 alter 语句重建主键索引是否合理。

在评论区，有同学问到为什么要重建索引。我们文章里面有提到，索引可能因为删除，或者页分裂等原因，导致数据页有空洞，重建索引的过程会创建一个新的索引，把数据按顺序插入，这样页面的利用率最高，也就是索引更紧凑、更省空间。

这道题目，我给你的“参考答案”是：

重建索引 k 的做法是合理的，可以达到省空间的目的。但是，重建主键的过程不合理。不论是删除主键还是创建主键，都会将整个表重建。所以连着执行这两个语句的话，第一个语句就白做



了。这两个语句，你可以用这个语句代替：`alter table T engine=InnoDB`。在专栏的第12篇文章《为什么表数据删掉一半，表文件大小不变？》中，我会和你分析这条语句的执行流程。

评论区留言中，@壹笙<sup>📧</sup>漂泊 做了很详细的笔记，@高枕 帮同学解答了问题，@约书亚 提了一个很不错的面试问题。在这里，我要和你们道一声感谢。

PS：如果你在面试中，曾有过被MySQL相关问题难住的经历，也可以把这个问题发到评论区，我们一起来讨论。如果解答这个问题，需要的篇幅会很长的话，我可以放到答疑文章展开。



©版权归极客邦科技所有，未经许可不得转载

上一篇 04 | 深入浅出索引（上）

写留言

#### 精选留言



约书亚

👍 2

疑问：

1. 有些资料提到，在不影响排序结果的情况下，在取出主键后，回表之前，会在对所有获取到的主键排序，请问是否存在这种情况？
2. 索引下推那个例子，感觉5.6之前的机制很匪夷所思：感觉判断'张%'之后再“看age的值”是顺理成章的事。难道联合索引的底层实现结构在这期间发生了变化？

2018-11-23

作者回复

1. 有的，Multi-Range Read (MRR) 由于不论是否使用这个策略，SQL语句写法不变，就没有在正文中提

2. 不是，是接口能力发生了变化，以前只能传“搜索关键字”。

如果你用过5.1 甚至5.0，在从现在的观点看，你会发现很多“匪夷所思”。还有：并行复制官方5.6才引入、MDL 5.5 才有、InnoDB 自增主键持久化、多源复制、online DDL ...

只能说，持续进化，幸甚至哉😊

2018-11-23



benson42

13

这两个语句，你可以用这个语句代替：`alter table T engine=InnoDB`。可以解释一下原理吗。

2018-11-23



gether

7

ca索引可以去掉，cb索引可以保留。

ca索引，通过索引对数据进行筛选，回表的时候，a本身就是主键索引，所以可以保证有序；cb索引，b上并没有索引，ab索引也无法满足最左匹配原则，可以保留加快排序速度。

但如果查询结果很少的话，内存中排序也够了吧，也没必要建立cb索引。老师，我理解的对不？

2018-11-23



工资不交税

7

老师好，文章提到建立一个（身份证号、姓名）的联合索引，是不是浪费空间？后文解释如果根据身份证号查询姓名和年龄就会用到覆盖索引。这里我不理解的是，年龄并不在联合索引内，那是不是应该回表啊？

2018-11-23



DanielAnton

1

请教老师，建立联合索引（身份证号，姓名），在根据身份证号查询姓名和年龄时，由于年龄字段没有出现在索引中，不还是需要再回表一次，查询年龄吗？

2018-11-23

作者回复

查年龄要，

覆盖索引是“根据身份证号查姓名”才有效

2018-11-23



HwangZHen

1

包含主键后应该是cab，根据最左匹配原则，cb是有必要的，ca没有必要

2018-11-23



ken

👍 1

思考题:

这两个索引是有必要的。新增这两个索引，可以在联合索引树直接过滤掉不满足条件的记录，减少回表次数

2018-11-23



Linuxer

👍 1

课后思考，如果主键为(a,b)那么啊肯定是有序的，貌似(c,a)索引就没必要，但是上面主键没法保证b的顺序，所以(c,b)建索引就有必要，c值一样的情况下，b是有序的，直接回表取就行。两个查询都能用这个索引

2018-11-23



滩涂曳尾

👍 1

老师，有两个细节:

1. MySQL5.6以后索引下推优化，这是优化器做的吗？
2. 回表这步是innodb存储引擎层做的吗

2018-11-23



一笑奈何

👍 1

需要注意的是，在引擎内部使用覆盖索引在索引 k 上其实读了三个记录，R3~R5，但是对于MySQL的Server层来说，它就是找引擎拿到了两条记录，因此MySQL认为扫描行数是2。

两条记录是指between 3 and 5吗？

2018-11-23



梦康

👍 1

图4中是5.6的话，会在回表的时候再优化iops吗？比如查到的是满足条件的1000行张三，会先对其id做排序，然后再回表么？这样挨得近的主键的I/O操作就能合并了。会有这样的优化吗？

2018-11-23



任鹏斌

👍 1

老师有个疑问用身份证号查询姓名和年龄不用回表，那么身份证号索引和姓名年龄联合索引是在两个索引树上维护吗？如果这样的话先从身份证号索引树中取到主键值，然后又根据主键值去姓名年龄索引树种搜索跟直接回表查询有什么区别？不是很明白这个详细过程希望老师解答一下。🙏

2018-11-23



阿建

👍 1

创建了ca cb索引之后，我觉得可以省去了最后对结果的排序。

2018-11-23



诸事顺意，六时吉祥

👍 0

思考题：我觉得只要把c和b分别建立索引就行了，orderBy a的时候可以用主键，orderBy b的时候可以用单独的b

2018-11-23



诸事顺意，六时吉祥

0

老师讲的调理和文章结构都是清楚仔细，真是看不厌啊，期待周一更新！

2018-11-23



lionetes

0

alter table T engine=InnoDB 是用来释放 delete 操作引起的页的空洞,也就是碎片空间 操作时候尽量避免当前表的dml 操作.

表数据很大情况 建议使用 Percona Toolkit 工具来执行

5.6版本的 ICP 对分区表没有作用吧, 子查询也要失去作用, ICP 用于range , ref , eq\_ref和ref\_or\_null访问方法 涉及到 ICP 的使用 查询过程要表的整行才有效？

ca cb 索引 感觉 都没有问题

from : mysql 文档

In this query, key\_part1 is constant, so all rows accessed through the index are in key\_part2 order, and an index on (key\_part1, key\_part2) avoids sorting if the WHERE clause is selective enough to make an index range scan cheaper than a table scan:

2018-11-23



喔~

0

建立了(name, age)的联合索引之后，例子中的检索如下：

```
mysql> select * from tuser where name like '张 %' and age=10 and ismale=1;
```

如果改为：

```
mysql> select * from tuser where age=10 and name like '张 %' and ismale=1;
```

这样优化器是否能够作出优化调整，还是直接走全表搜索？

2018-11-23



李志博

0

我觉得是对的，由于最左前缀原则，按b排序那个会出现using file sort

2018-11-23



Acrisius

0

课后答题：

一开始也觉得是只需要CB索引，但是根据题目实际操作了一下，得到的结果是select .. from geek where c=1 order by a 这一条，假设在只有CB索引的情况下，是不会用到AB索引的，

索引是根据条件来判断是否使用索引，条件只有C=1所以AB索引不会被用，只会用到CB索引，得到结果集后再对结果集进行排序，所以建立CA索引是没有问题的。

老师有个问题请教一下，就是这个问题 CA和CB索引 就只能使用在单表查询这个场景，那在数据量庞大的情况下，单索引与联合索引所占缓存空间跟优化的时间的取舍，在多表join的时候，联合索引的应用场景

2018-11-23



cb索引是必须的，ca索引是不必要的

2018-11-23

👍 0