讲堂 > MySQL实战45讲 > 文章详情

18 | 为什么这些SQL语句逻辑相同, 性能却差异巨大?

2018-12-24 林晓斌





18 | 为什么这些SQL语句逻辑相同,性能却差异巨大?

朗读人: 林晓斌 15'33" | 14.26M

在 MySQL 中,有很多看上去逻辑相同,但性能却差异巨大的 SQL 语句。对这些语句使用不当的话,就会不经意间导致整个数据库的压力变大。

我今天挑选了三个这样的案例和你分享。希望再遇到相似的问题时,你可以做到举一反三、快速解决问题。

案例一:条件字段函数操作

假设你现在维护了一个交易系统,其中交易记录表 tradelog 包含交易流水号(tradeid)、交易员 id(operator)、交易时间(t_modified)等字段。为了便于描述,我们先忽略其他字段。这个表的建表语句如下:

1 mysql> CREATE TABLE `tradelog` (

- 2 `id` int(11) NOT NULL,
- 3 `tradeid` varchar(32) DEFAULT NULL,
- 4 `operator` int(11) DEFAULT NULL,
- 5 `t_modified` time DEFAULT NULL,

■ 复制代码

```
PRIMARY KEY (`id`),

KEY `tradeid` (`tradeid`),

KEY `t_modified` (`t_modified`)

PRIMARY KEY (`id`),

ENGINE=InnoDB DEFAULT CHARSET=utf8mb4;
```

假设,现在已经记录了从 2016 年初到 2018 年底的所有数据,运营部门有一个需求是,要统计发生在所有年份中 7 月份的交易记录总数。这个逻辑看上去并不复杂,你的 SQL 语句可能会这么写:

```
1 mysql> select count(*) from tradelog where month(t_modified)=7;
```

由于 t_modified 字段上有索引,于是你就很放心地在生产库中执行了这条语句,但却发现执行了特别久,才返回了结果。

如果你问 DBA 同事为什么会出现这样的情况,他大概会告诉你:如果对字段做了函数计算,就用不上索引了,这是 MySQL 的规定。

现在你已经学过了 InnoDB 的索引结构了,可以再追问一句为什么?为什么条件是 where t_modified='2018-7-1' 的时候可以用上索引,而改成 where month(t_modified)=7 的时候就不行了?

下面是这个 t modified 索引的示意图。方框上面的数字就是 month() 函数对应的值。

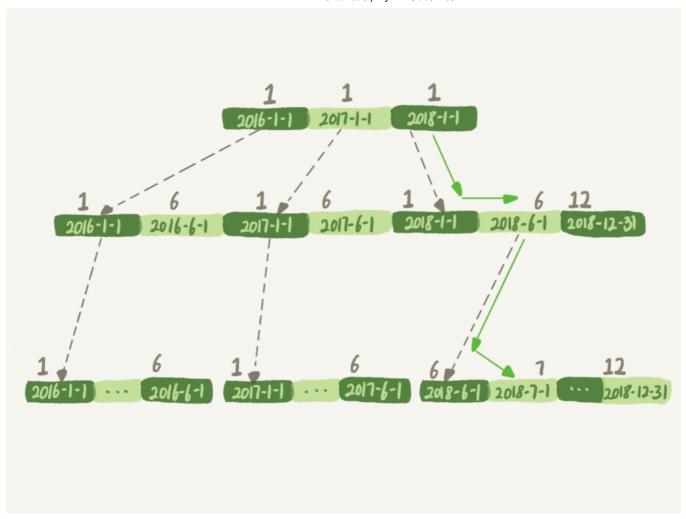


图 1 t modified 索引示意图

如果你的 SQL 语句条件用的是 where $t_modified='2018-7-1'$ 的话,引擎就会按照上面绿色箭头的路线,快速定位到 $t_modified='2018-7-1'$ 需要的结果。

实际上, B+ 树提供的这个快速定位能力, 来源于同一层兄弟节点的有序性。

但是,如果计算 month()函数的话,你会看到传入7的时候,在树的第一层就不知道该怎么办了。

也就是说,**对索引字段做函数操作,可能会破坏索引值的有序性,因此优化器就决定放弃走树搜索功能。**

需要注意的是,优化器并不是要放弃使用这个索引。

在这个例子里,放弃了树搜索功能,优化器可以选择遍历主键索引,也可以选择遍历索引 t_modified,优化器对比索引大小后发现,索引 t_modified 更小,遍历这个索引比遍历主键索引来得更快。因此最终还是会选择索引 t_modified。

接下来,我们使用 explain 命令,查看一下这条 SQL 语句的执行结果。

mysql>			from tradelog	-	month(t_modified						
id	select_type	table	partitions	type	possible_keys	key	key_len	ref	rows	filtered	Extra
1	SIMPLE	tradelog	NULL	index	NULL	t_modified	6	NULL	100335	100.00	Using where; Using index
											,

图 2 explain 结果

key="t_modified"表示的是,使用了 t_modified 这个索引;我在测试表数据中插入了 10 万行数据,rows=100335,说明这条语句扫描了整个索引的所有值;Extra 字段的 Using index,表示的是使用了覆盖索引。

也就是说,由于在 t_modified 字段加了 month() 函数操作,导致了全索引扫描。为了能够用上索引的快速定位能力,我们就要把 SQL 语句改成基于字段本身的范围查询。按照下面这个写法,优化器就能按照我们预期的,用上 t modified 索引的快速定位能力了。

```
1 mysql> select count(*) from tradelog where
2 -> (t_modified >= '2016-7-1' and t_modified<'2016-8-1') or
3 -> (t_modified >= '2017-7-1' and t_modified<'2017-8-1') or
4 -> (t_modified >= '2018-7-1' and t_modified<'2018-8-1');
```

当然,如果你的系统上线时间更早,或者后面又插入了之后年份的数据的话,你就需要再把其他 年份补齐。

到这里我给你说明了,由于加了 month() 函数操作,MySQL 无法再使用索引快速定位功能,而只能使用全索引扫描。

不过优化器在个问题上确实有"偷懒"行为,即使是对于不改变有序性的函数,也不会考虑使用索引。比如,对于 select * from tradelog where id + 1 = 10000 这个 SQL 语句,这个加 1操作并不会改变有序性,但是 MySQL 优化器还是不能用 id 索引快速定位到 9999 这一行。所以,需要你在写 SQL 语句的时候,手动改写成 where id = 10000 -1 才可以。

案例二: 隐式类型转换

接下来我再跟你说一说,另一个经常让程序员掉坑里的例子。

我们一起看一下这条 SQL 语句:

```
1 mysql> select * from tradelog where tradeid=110717;
```

交易编号 tradeid 这个字段上,本来就有索引,但是 explain 的结果却显示,这条语句需要走全表扫描。你可能也发现了,tradeid 的字段类型是 varchar(32),而输入的参数却是整型,所以需要做类型转换。

那么, 现在这里就有两个问题:

- 1. 数据类型转换的规则是什么?
- 2. 为什么有数据类型转换,就需要走全索引扫描?

先来看第一个问题, 你可能会说, 数据库里面类型这么多, 这种数据类型转换规则更多, 我记不住, 应该怎么办呢?

这里有一个简单的方法,看 select "10" > 9 的结果:

- 1. 如果规则是"将字符串转成数字",那么就是做数字比较,结果应该是1;
- 2. 如果规则是"将数字转成字符串",那么就是做字符串比较,结果应该是0。

验证结果如图 3 所示。

```
mysql> select "10" > 9;
+-----+
| "10" > 9 |
+-----+
| 1 |
```

图 3 MySQL 中字符串和数字转换的效果示意图

从图中可知, select "10" > 9返回的是 1, 所以你就能确认 MySQL 里的转换规则了:在 MySQL 中,字符串和数字做比较的话,是将字符串转换成数字。

这时, 你再看这个全表扫描的语句:

```
1 mysql> select * from tradelog where tradeid=110717;
```

就知道对于优化器来说,这个语句相当于:

```
1 mysql> select * from tradelog where CAST(tradid AS signed int) = 110717;
```

也就是说,这条语句触发了我们上面说到的规则:对索引字段做函数操作,优化器会放弃走树搜索功能。

现在,我留给你一个小问题,id 的类型是 int, 如果执行下面这个语句,是否会导致全表扫描呢?

```
1 select * from tradelog where id="83126";
```

你可以先自己分析一下,再到数据库里面去验证确认。

接下来,我们再来看一个稍微复杂点的例子。

案例三: 隐式字符编码转换

假设系统里还有另外一个表 trade_detail,用于记录交易的操作细节。为了便于量化分析和复现,我往交易日志表 tradelog 和交易详情表 trade detail 这两个表里插入一些数据。

```
■ 复制代码
1 mysql> CREATE TABLE `trade_detail` (
    `id` int(11) NOT NULL,
    `tradeid` varchar(32) DEFAULT NULL,
     `trade_step` int(11) DEFAULT NULL, /* 操作步骤 */
    `step_info` varchar(32) DEFAULT NULL, /* 步骤信息 */
    PRIMARY KEY (`id`),
    KEY `tradeid` (`tradeid`)
8 ) ENGINE=InnoDB DEFAULT CHARSET=utf8;
insert into tradelog values(1, 'aaaaaaaa', 1000, now());
insert into tradelog values(2, 'aaaaaaaab', 1000, now());
12 insert into tradelog values(3, 'aaaaaaaac', 1000, now());
13
14 insert into trade_detail values(1, 'aaaaaaaa', 1, 'add');
insert into trade_detail values(2, 'aaaaaaaaa', 2, 'update');
16 insert into trade_detail values(3, 'aaaaaaaaa', 3, 'commit');
17 insert into trade_detail values(4, 'aaaaaaaab', 1, 'add');
18 insert into trade_detail values(5, 'aaaaaaaab', 2, 'update');
19 insert into trade_detail values(6, 'aaaaaaaab', 3, 'update again');
20 insert into trade_detail values(7, 'aaaaaaaab', 4, 'commit');
21 insert into trade_detail values(8, 'aaaaaaaac', 1, 'add');
22 insert into trade_detail values(9, 'aaaaaaaac', 2, 'update');
23 insert into trade_detail values(10, 'aaaaaaaac', 3, 'update again');
24 insert into trade detail values(11, 'aaaaaaaac', 4, 'commit');
```

这时候,如果要查询 id=2 的交易的所有操作步骤信息,SQL 语句可以这么写:

```
1 mysql> select d.* from tradelog l, trade_detail d where d.tradeid=l.tradeid and l.id=2;
nysql> explain select d.* from tradelog l , trade_detail d where d.tradeid=l.tradeid and l.id=2;
 id | select_type | table | partitions | type
                                                                                          | rows | filtered | Extra
                                             | possible_keys
                                                               | key
                                                                        | key_len | ref
     SIMPLE
                          NULL
                                               PRIMARY, tradeid
                                                                PRIMARY I
                                                                                                     100.00
                                                                                                             NULL
                                       const
                                                                                    const
                                                                          NULL
     SIMPLE
                          NULL
                                               NULL
                                                                NULL
                                                                                    NULL
                                                                                                     100.00
                                                                                                             Using where
                                       ALL
```

图 4 语句 Q1 的 explain 结果

我们一起来看下这个结果:

- 1. 第一行显示优化器会先在交易记录表 tradelog 上查到 id=2 的行,这个步骤用上了主键索引,rows=1 表示只扫描一行;
- 2. 第二行 key=NULL,表示没有用上交易详情表 trade_detail 上的 tradeid 索引,进行了全表扫描。

在这个执行计划里,是从 tradelog 表中取 tradeid 字段,再去 trade_detail 表里查询匹配字段。因此,我们把 tradelog 称为驱动表,把 trade_detail 称为被驱动表,把 tradeid 称为关联字段。

接下来,我们看下这个 explain 结果表示的执行流程:

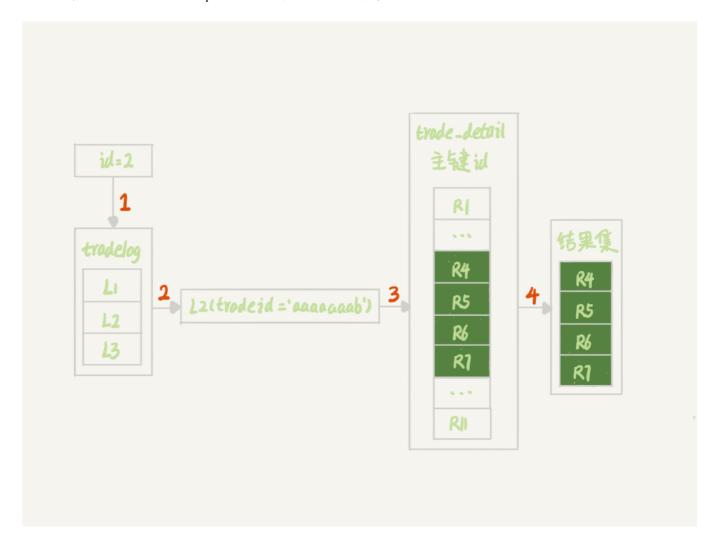


图 5 语句 Q1 的执行过程

图中:

- 第 1 步, 是根据 id 在 tradelog 表里找到 L2 这一行;
- 第 2 步, 是从 L2 中取出 tradeid 字段的值;
- 第 3 步,是根据 tradeid 值到 trade_detail 表中查找条件匹配的行。explain 的结果里面第二行的 key=NULL 表示的就是,这个过程是通过遍历主键索引的方式,一个一个地判断 tradeid 的值是否匹配。

进行到这里,你会发现第 3 步不符合我们的预期。因为表 trade_detail 里 tradeid 字段上是有索引的,我们本来是希望通过使用 tradeid 索引能够快速定位到等值的行。但,这里并没有。

如果你去问 DBA 同学,他们可能会告诉你,因为这两个表的字符集不同,一个是 utf8, 一个是 utf8mb4, 所以做表连接查询的时候用不上关联字段的索引。这个回答,也是通常你搜索这个问题时会得到的答案。

但是你应该再追问一下,为什么字符集不同就用不上索引呢?

我们说问题是出在执行步骤的第3步,如果单独把这一步改成 SQL 语句的话,那就是:

```
1 mysql> select * from trade_detail where tradeid=$L2.tradeid.value;
```

■ 复制代码

其中, \$L2.tradeid.value 的字符集是 utf8mb4。

参照前面的两个例子,你肯定就想到了,字符集 utf8mb4 是 utf8 的超集,所以当这两个类型的字符串在做比较的时候,MySQL 内部的操作是,先把 utf8 字符串转成 utf8mb4 字符集,再做比较。

这个设定很好理解, utf8mb4 是 utf8 的超集。类似地, 在程序设计语言里面, 做自动类型转换的时候, 为了避免数据在转换过程中由于截断导致数据错误, 也都是"按数据长度增加的方向"进行转换的。

因此, 在执行上面这个语句的时候, 需要将被驱动数据表里的字段一个个地转换成 utf8mb4, 再跟 L2 做比较。

也就是说,实际上这个语句等同于下面这个写法:

```
1 select * from trade_detail where CONVERT(traideid USING utf8mb4)=$L2.tradeid.value;
```

CONVERT() 函数,在这里的意思是把输入的字符串转成 utf8mb4 字符集。

这就再次触发了我们上面说到的原则:对索引字段做函数操作,优化器会放弃走树搜索功能。

到这里,你终于明确了,字符集不同只是条件之一,**连接过程中要求在被驱动表的索引字段上加 函数操作**,是直接导致对被驱动表做全表扫描的原因。

作为对比验证,我给你提另外一个需求,"查找 trade_detail 表里 id=4 的操作,对应的操作者是谁",再来看下这个语句和它的执行计划。

```
1 mysql>select l.operator from tradelog l , trade_detail d where d.tradeid=l.tradeid and d.id=4;
```

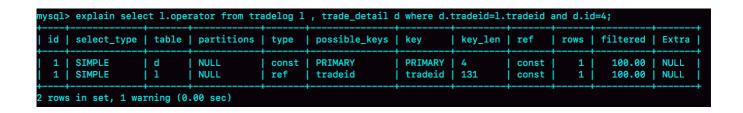


图 6 explain 结果

这个语句里 trade_detail 表成了驱动表,但是 explain 结果的第二行显示,这次的查询操作用上了被驱动表 tradelog 里的索引 (tradeid),扫描行数是 1。

这也是两个 tradeid 字段的 join 操作,为什么这次能用上被驱动表的 tradeid 索引呢?我们来分析一下。

假设驱动表 trade_detail 里 id=4 的行记为 R4,那么在连接的时候(图 5 的第 3 步),被驱动表 tradelog 上执行的就是类似这样的 SQL 语句:

```
1 select operator from tradelog where traideid =$R4.tradeid.value;
```

这时候 \$R4.tradeid.value 的字符集是 utf8, 按照字符集转换规则,要转成 utf8mb4,所以这个过程就被改写成:

```
复制代码
1 select operator from tradelog where traideid =CONVERT($R4.tradeid.value USING utf8mb4);
```

你看,这里的 CONVERT 函数是加在输入参数上的,这样就可以用上被驱动表的 traideid 索引。

理解了原理以后,就可以用来指导操作了。如果要优化语句

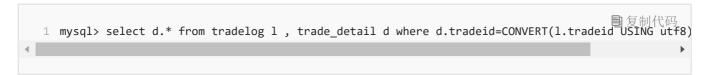
```
1 select d.* from tradelog l, trade_detail d where d.tradeid=l.tradeid and l.id=2;
```

的执行过程,有两种做法:

• 比较常见的优化方法是,把 trade_detail 表上的 tradeid 字段的字符集也改成 utf8mb4, 这样就没有字符集转换的问题了。

1 alter table trade_detail modify tradeid varchar(32) CHARACTER SET utf8mb4 default null;

如果能够修改字段的字符集的话,是最好不过了。但如果数据量比较大,或者业务上暂时不能做这个 DDL 的话,那就只能采用修改 SQL 语句的方法了。



id	select_type	table	partitions	type	possible_keys	key	key_len	ref	rows	filtered	Extra
1	SIMPLE	1	NULL	const	PRIMARY	PRIMARY	4	const	1	100.00	NULL
1	SIMPLE	d	NULL	ref	tradeid	tradeid	99	const	4	100.00	NULL

图 7 SQL 语句优化后的 explain 结果

这里,我主动把 l.tradeid 转成 utf8,就避免了被驱动表上的字符编码转换,从 explain 结果可以看到,这次索引走对了。

小结

今天我给你举了三个例子,其实是在说同一件事儿,即:**对索引字段做函数操作,可能会破坏索 引值的有序性,因此优化器就决定放弃走树搜索功能。**

第二个例子是隐式类型转换,第三个例子是隐式字符编码转换,它们都跟第一个例子一样,因为要求在索引字段上做函数操作而导致了全索引扫描。

MySQL 的优化器确实有"偷懒"的嫌疑,即使简单地把 where id+1=1000 改写成 where id=1000-1 就能够用上索引快速查找,也不会主动做这个语句重写。

因此,每次你的业务代码升级时,把可能出现的、新的 SQL 语句 explain 一下,是一个很好的习惯。

最后,又到了思考题时间。

今天我留给你的课后问题是,你遇到过别的、类似今天我们提到的性能问题吗?你认为原因是什么,又是怎么解决的呢?

你可以把你经历和分析写在留言区里,我会在下一篇文章的末尾选取有趣的评论跟大家一起分享和分析。感谢你的收听,也欢迎你把这篇文章分享给更多的朋友一起阅读。

上期问题时间

我在上篇文章的最后,留给你的问题是:我们文章中最后的一个方案是,通过三次 limit Y,1 来得到需要的数据,你觉得有没有进一步的优化方法。

这里我给出一种方法,取 Y1、Y2 和 Y3 里面最大的一个数,记为 M,最小的一个数记为 N,然后执行下面这条 SQL 语句:

1 mysql> select * from t limit N, M-N+1;

目复制代码

再加上取整个表总行数的 C 行,这个方案的扫描行数总共只需要 C+M 行。

当然也可以先取回 id 值,在应用中确定了三个 id 值以后,再执行三次 where id=X 的语句也是可以的。@倪大人 同学在评论区就提到了这个方法。

这次评论区出现了很多很棒的留言:

@老杨同志 提出了重新整理的方法、@雪中鼠 [悠闲] 提到了用 rowid 的方法,是类似的思路,就是让表里面保存一个无空洞的自增值,这样就可以用我们的随机算法 1 来实现;

@吴宇晨 提到了拿到第一个值以后,用 id 迭代往下找的方案,利用了主键索引的有序性。



©版权归极客邦科技所有, 未经许可不得转载

上一篇 17 | 如何正确地显示随机消息?

写留言

精选留言



沙漠里的骆驼

心()

参数一样,但结果数据集不一样;

比如一个字段有索引(非唯一),满足条件的只有几条,和有几万条甚至几十万条,执行后性能 差异会比较大;这也是非常不可控的。

2018-12-24



undifined

心

1. select * from tradelog where id="83126"; 不会全表扫描,因为会先将 "83126"转换成整数,并不会影响到索引

2.查询 id=2 的交易的所有操作步骤信息的 SQL

select d.* from tradelog l, trade_detail d where d.tradeid=l.tradeid and l.id=2; 改成子查询

SELECT * FROM trade_detail WHERE tradeid = (SELECT tradeid FROM tradelog WHER E id = 2);

可以避免编码转换的问题,请问老师子查询和原来的查询效率会有差别吗

3.遇到过一个类型转换的问题: order 表的 status 字段是int 类型的,但是传入的参数是字符串:

select * from order where status = 's'; 这里查到了 status 为 0 的数据,我的理解是对 's'做了隐式类型转换,但是转换的过程没有匹配 's'的数值,所以使用了默认值 0,老师这样 理解对吗

4. select * 和 select 所有字段的差别是什么,会有效率问题吗,麻烦老师帮忙解答一下,谢谢老师

2018-12-24



小文

心 ()

如果tradeid是字符串类型, where tradeid=110717不是直接就报错了么⊙∀⊙!

2018-12-24



asdf100

ம் ()

t modified 是 time类型可以使用 month函数求出来月份?

2018-12-24



约书亚

ம் 0

谁是驱动表谁是被驱动表,是否大多数情况看where条件就可以了?这是否本质上涉及到mys ql底层决定用什么算法进行级联查询的问题?后面会有课程详细说明嘛?

2018-12-24

慧鑫coming

心 ()



意犹未尽

2018-12-24



尘封

心 ①

老师,多表关联时,执行计划里的id是否有规律可寻?比如id相同的是从上到下执行?id不同的是从小到大执行。

2018-12-24



Justin

心 0

现在,我留给你一个小问题,id 的类型是 int, 如果执行下面这个语句,是否会导致全表扫描呢?

回答文中问题 我觉得不会 因为string类型是在参数侧,即使被cast 成 int 也会走索引的 不知理解的对不对?

2018-12-24